

Ciência dos Dados I: Análise Exploratória

Aula 01: Introdução e História da Computação à Ciência dos Dados

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Curso de Física Médica

Versão 2026

Sumário da Aula

Introdução e a Metáfora dos Dados

Primórdios da Coleta e Registro de Dados

Instrumentos de Cálculo e Análise Pré-Eletrônicos

O Nascimento da Computação Moderna (1940–1950)

A Dinâmica dos Dados e seus Riscos (1960–1970)

Supercomputação e Redes (1980–1990)

A Era dos Grandes Dados Biomédicos (2000–2026)

O Ciclo de Vida da Ciência de Dados e 2026

O Catálogo de Leporello em Don Giovanni

Na ópera de Mozart e Da Ponte (1787), o servo Leporello apresenta o registro metódico das conquistas de Don Giovanni:

*"Madamina, il catalogo è questo
delle belle, che amò il padron mio;
un catalogo egli è, che ho fatt'io.
In Italia seicento e quaranta,
in Almagna duecento e trentuna,
cento in Francia, in Turchia novantuna,
ma in Ispagna son già mille e tre!"*

O que é este Catálogo?

- **Coleta sistemática** de observações.
- **Estratificação** por categorias (geografia, estrato social, idade).
- **Agregação quantitativa**: uma autêntica prefiguração da análise exploratória!

O que é Ciência de Dados?

Definição: Disciplina que combina métodos científicos, processos algorítmicos e inteligência quantitativa para extrair conhecimento de dados ruidosos.

- **Computação e Engenharia:** manipulação eficiente, código limpo, reprodutibilidade.
- **Matemática e Estatística:** inferência, distribuições, modelagem e incerteza.
- **Conhecimento de Domínio:** Física Médica, Biologia, Saúde e Biofísica.

John Tukey (1962)

"A análise exploratória de dados é uma atitude, uma flexibilidade e uma disposição para buscar coisas além do que esperávamos encontrar."

O Papel da EDA

Compreender a estrutura dos dados antes de qualquer hipótese ou modelo preditivo.

As Cheias do Nilo: Previsão e Séries Temporais Antigas

- A civilização egípcia dependia criticamente do regime anual de cheias do Rio Nilo para a agricultura.
- A narrativa bíblica de José no Egito ilustra a gestão baseada em previsão de safras e armazenamento estratégico de estoques.
- **Nilômetros:** marcos de pedra que registravam historicamente os níveis do rio – uma das primeiras bases de dados de séries temporais da humanidade.




Fig. 1. Height of ancient Nile floods in metres above arbitrary zero (left); black dots = individual floods, X = averages; and (right) height of modern floods measured at Roda, in metres above sea level

Registros e dinâmica histórica de inundações.

A Tableta Suméria: Os Primeiros Registros Contábeis

- Na Mesopotâmia (c. 3200 a.C.), a escrita cuneiforme em argila não nasceu para a poesia, mas para a **contabilidade**.
- Registros detalhados de sacas de cevada, rebanhos, impostos e transações comerciais.
- O dado enquanto prova documental e base para a tomada de decisões administrativas do Estado sumério.





Figure 1. Plimpton 322 (obverse). Drawing by the author.

Tableta suméria em argila com registros contábeis.

O Ábaco: A Computação Mecânica

- Utilizado na Babilônia, China, Grécia e Roma antiga.
- Representação posicional de números e realização rápida de operações aritméticas fundamentais.
- A primeira grande abstração: separar o **dado bruto** da **operação computacional** realizada sobre ele.



Ábaco tradicional: ferramenta de cálculo aritmético.

O Astrolábio: Instrumento Astronômico e Analógico


- Desenvolvido na Antiguidade helenística e aperfeiçoado no Mundo Islâmico medieval.
- Computador analógico bidimensional para cálculo da posição do Sol, estrelas e navegação.
- Transformação de coordenadas esféricas celestes para o plano (projeção estereográfica).



Astrolábio persa do século XVIII.

Tycho Brahe, Kepler e a Astronomia Guiada por Dados


- **Tycho Brahe (1546–1601):** Realizou décadas de medições astronômicas com precisão sem precedentes, sem o uso de telescópios.
- **Johannes Kepler (1571–1630):** Analisou meticulosamente os dados tabulares de Marte herdados de Tycho.
- **Conclusão:** Ao confiar nos dados empíricos em vez de dogmas circulares, Kepler deduziu que as órbitas planetárias são **elipses**!



O sistema cosmológico tichônico.

A Régua de Cálculo: Três Séculos de Engenharia


- Inventada por William Oughtred no século XVII baseada nos logaritmos de John Napier.
- Converte multiplicações e divisões em adições e subtrações visuais de comprimentos logarítmicos.
- Foi o instrumento computacional de cientistas e engenheiros até o Projeto Apollo na década de 1960!



Régua de cálculo portátil.

Gregor Mendel: A Estatística nas Origens da Genética


- O monge agostiniano Gregor Mendel (1822–1884) cultivou cerca de 28.000 pés de ervilha.
- Contagem sistemática de traços fenotípicos (amarelo/verde, liso/rugoso).
- A proporção matemática observada de 3 : 1 permitiu inferir a existência de fatores hereditários discretos (genes) muito antes do conhecimento molecular do DNA!



Gregor Mendel e os dados empíricos de segregação.

Alan Turing e os Fundamentos da Computabilidade


- **1936:** Artigo seminal sobre os Números Computáveis e o conceito formal da Máquina de Turing.
- **Segunda Guerra Mundial (Bletchley Park):** Projeto da máquina eletromecânica *Bombe* para decifrar as transmissões navais nazistas codificadas pela máquina Enigma.
- **1950:** O artigo "*Computing Machinery and Intelligence*" e o célebre Teste de Turing.



Alan Turing (1912–1954).

ENIAC e o Laboratório de Los Alamos


- **ENIAC (1945):** Primeiro computador digital eletrônico de grande escala e de uso geral.
- Com mais de 17.000 válvulas termiônicas, realizava milhares de cálculos por segundo.
- **Física Computacional:** Utilizado por John von Neumann, Stanislaw Ulam e Nicholas Metropolis para desenvolver o **Método de Monte Carlo**, crucial para simulações nucleares.



ENIAC em operação no Laboratório de Los Alamos.

O Atrator de Lorenz: Caos Determinístico


- **Edward Lorenz (1963)**: Modelo simplificado de convecção atmosférica com 3 equações diferenciais acopladas.
- **Efeito Borboleta**: Sensibilidade extrema às condições iniciais – pequenas variações decimais mudam completamente o desfecho futuro.
- Lição para o cientista de dados: modelos complexos dependem criticamente da precisão e incerteza dos dados de entrada.



O atrator estranho de Lorenz no espaço de fase.

A Falácia de McNamara: Os Perigos das Métricas Cegas

- Robert McNamara (Secretário de Defesa dos EUA) aplicou gestão estritamente quantitativa na Guerra do Vietnã ("*body count*").
- **A Falácia:**
 - 1 Medir tudo o que pode ser medido facilmente.
 - 2 Ignorar o que não pode ser facilmente quantificado.
 - 3 Presumir que o que não é medido não tem relevância.
 - 4 Dizer que o que não é medido não existe.
- **Alerta vital:** Dados sem contexto substantivo levam a catástrofes decisórias!



Robert McNamara e a falácia das métricas isoladas.

A Revolução da HP-35 (1972)

- Primeira calculadora científica de bolso do mundo, criada pela Hewlett-Packard.
- Calculava funções trigonométricas e logarítmicas instantaneamente com notação polonesa reversa (RPN).
- Tornou a régua de cálculo obsoleta praticamente do dia para a noite nos laboratórios de física e engenharia.



Calculadora científica HP-35 (1972).

Seymour Cray e os Supercomputadores Vetoriais

- O **Cray-1 (1976)** introduziu arquitetura vetorial integrada de alto desempenho.
- Formato icônico em ferradura para minimizar o comprimento dos fios e o atraso dos sinais elétricos.
- Viabilizou simulações pioneiras de dinâmica molecular, meteorologia e física de plasmas.



Supercomputador Cray-1.

O Projeto Genoma Humano (2001)


- Em fevereiro de 2001, a revista *Nature* publica a sequência preliminar do genoma humano (3 bilhões de pares de bases).
- Marco histórico: a Biologia e a Física Médica transformam-se em ciências essencialmente computacionais e baseadas em dados (*data-driven*).
- Demanda maciça por novos algoritmos de alinhamento, estatística e bioinformática.



Capa histórica da revista *Nature* (Fev/2001).

Conectoma (2010–2020)

- **Human Connectome Project (HCP):** Mapeamento das conexões neurais estruturais e funcionais do cérebro humano.
- Fusão de Ressonância Magnética por Difusão (dMRI), fMRI e teoria dos grafos.
- **Resolução Milimétrica:** Cada voxel (1 a 2 mm) agrupa centenas de milhares de axônios.
- Mapeia os grandes feixes de substância branca e hubs de conectividade global.



Tratografia por difusão (dMRI) e macro-conectoma cerebral.

Micro-Conectoma (2024–2026)

O Salto da Escala Nanométrica (*Science*, 2024)

Pesquisadores de **Harvard** e **Google Research** reconstruíram 1 mm³ de córtex temporal humano em resolução sináptica:

- **Amostra:** 1 mm³ (metade de um grão de arroz!).
- **Volume de Dados:** 1,4 Petabytes (1.400 Terabytes) gerados por microscopia eletrônica serial.
- **Complexidade:** 57.000 células e **150 milhões de sinapses** mapeadas.

O Papel da Ciência de Dados e IA


A reconstrução manual levaria séculos. Redes neurais de visão computacional da Google segmentaram automaticamente os petabytes de voxels.

Conectoma Populacional (UK Biobank)

Mais de **100.000 cérebros** escaneados, integrando conectomas a dados genômicos e clínicos em larga escala.

O Ciclo de Vida dos Dados (Framework OSEMN)

- 1 **Obtain (Obter)**: Aquisição de bases, sensores, APIs.
- 2 **Scrub (Limpar)**: Tratamento de valores nulos, parsing.
- 3 **Explore (Explorar)**: Análise exploratória de dados (EDA).
- 4 **Model (Modelar)**: Regressão, classificação, clustering.
- 5 **iNterpret (Interpretar)**: Comunicação e tomada de decisão.



Esquema do fluxo e ciclo de vida dos dados.

A Ciência de Dados em 2026

- **Da Escassez ao Dilúvio:** O gargalo contemporâneo não é obter dados, mas destilar sinal a partir do ruído.
- **A Era da IA Generativa e LLMs:** Modelos de fundação atuam como copilotos analíticos, automatizando código básico e acelerando a exploração.
- **Ética e Governança:** Privacidade, LGPD/GDPR, viés algorítmico e auditoria de modelos clínicos na saúde.
- **Reprodutibilidade:** Princípios FAIR (*Findable, Accessible, Interoperable, Reusable*).

O Ecossistema Prático deste Curso

Python 3.12+, JupyterLab 4, Pandas 2.2+, NumPy 2.x, Matplotlib 3.9+, Seaborn e Scikit-Learn.

Resumo da Aula 01

- A necessidade de medir, registrar e analisar dados acompanha a humanidade desde os tabletas de argila e astronomia até o genoma e conectoma moderno.
- A Análise Exploratória (EDA) é o alicerce indispensável de qualquer empreendimento científico rigoroso.
- **Atividade Prática:** Acesse o caderno `Aula01_Pratica.ipynb` para configurar o ambiente e explorar o catálogo de dados em Python!