

Ciência dos Dados I: Análise Exploratória

Aula 04: Ambiente Unix/Linux, Linha de Comando e Controle de Versão

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

A Filosofia Unix

Streams e Utilitários Essenciais

Controle de Versão com Git e GitHub

Princípios do Design Unix

Formulada por Doug McIlroy e Ken Thompson nos laboratórios Bell:

- ① **Faça uma coisa bem feita:** Cada utilitário resolve uma tarefa específica com excelência.
- ② **Texto é a interface universal:** A saída de um programa pode ser a entrada de outro.
- ③ **Combine ferramentas simples:** O operador pipe (`|`) encadeia fluxos contínuos de dados.

Por que o Cientista de Dados deve dominar a CLI?

Permite filtrar, inspecionar e pré-processar arquivos de 100 GB no servidor em segundos, sem necessidade de alocar memória RAM com Pandas.

Comandos de Inspeção Rápida de Dados

- `head -n 10 arquivo.csv`: Exibe o cabeçalho e as primeiras linhas.
- `tail -n 10 arquivo.csv`: Inspecciona o final do arquivo (útil para detectar truncamentos).
- `wc -l arquivo.csv`: Conta o número total de linhas.
- `grep -i "termo" log.txt | wc -l`: Filtra padrões e conta correspondências.
- `cut -d ',' -f 1,3 arquivo.csv`: Isola colunas específicas em arquivos delimitados.

Reprodutibilidade e Versionamento

- **Git:** Sistema distribuído que rastreia snapshots do código ao longo do tempo.
- **Estados:** *Working Directory* → *Staging Area* → *Repository* (*.git*).
- **Branching:** Permite testar modelos e análises sem corromper a linha principal de produção.

Comandos Fundamentais

```
git clone <url>
git status
git add .
git commit -m "Mensagem"
git push origin main
```

- A linha de comando é a primeira linha de defesa no manuseio de dados brutos.
- O Git garante que nenhuma análise científica seja perdida ou substituída acidentalmente.
- **Prática:** Comandos de inspeção e contagem executados diretamente das células do Jupyter.