

Ciência dos Dados I: Análise Exploratória

Aula 08: Entrada/Saída de Arquivos e Leitura de Dados Compactados

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

Gerenciadores de Contexto

Formatos de Dados: Texto, CSV e Compactação

O Módulo Nativo `csv`

Manipulação Segura com with open

Nunca abra arquivos sem o gerenciador de contexto:

```
# Modo seguro: garante o fechamento do arquivo mesmo se ocorrer um erro
with open('dados.txt', 'r', encoding='utf-8') as f:
    for linha in f:
        print(linha.strip())
```

Por que especificar encoding='utf-8'?

Sistemas operacionais diferentes adotam codificações distintas por padrão (Windows costumava adotar cp1252; Linux adota UTF-8). Definir UTF-8 explicitamente garante portabilidade.

Lendo Arquivos Compactados sem Descompactar no Disco

Muitas séries temporais e dados genômicos são armazenados em formato comprimido (.gz) para economizar espaço de armazenamento:

```
import gzip

with gzip.open('arq_abril_outono.txt.gz', 'rt', encoding='utf-8') as f:
    primeira_linha = f.readline()
    print(primeira_linha)
```

Vantagem em Ciência de Dados

A descompressão ocorre em tempo real diretamente na memória durante a leitura de streaming, economizando dezenas de gigabytes de espaço em disco.

Leitura Estruturada com csv.reader e DictReader

```
import csv

with open('matriznum.csv', 'r', encoding='utf-8') as f:
    leitor = csv.reader(f)
    for linha in leitor:
        # linha é uma lista de strings: ['1.5', '2.3', '4.1']
        valores = [float(x) for x in linha if x]
```

Resumo da Aula

- Gerenciadores de contexto evitam vazamentos de descritores de arquivo no sistema operacional.
- Arquivos compactados podem ser lidos diretamente sem extração prévia.
- **Prática:** Leitura e sumarização de arquivos de texto, CSVs e dados compactados com gzip.