

Ciência dos Dados I: Análise Exploratória

Aula 09: Análise de Dados com Pandas I: Series, DataFrames e Indexação

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

O Papel do Pandas no Ecossistema

Indexação Rigorosa: `loc` vs. `iloc`

Filtros Booleanos e Sumários

Por que Pandas?

Criada por Wes McKinney em 2008, o Pandas é a espinha dorsal da análise de dados tabulares em Python:

- Combina o desempenho de vetores contíguos do NumPy com a flexibilidade de planilhas e bancos relacionais.
- Suporta rótulos explícitos de linhas e colunas (índices).
- Facilita alinhamento automático de dados e tratamento de dados ausentes.

Estruturas Centrais

- **Series:** Matriz unidimensional rotulada capaz de conter qualquer tipo de dados.
- **DataFrame:** Estrutura de dados tabular bidimensional com eixos rotulados (linhas e colunas).

Seleção de Dados sem Ambiguidade

`.loc[linhas, colunas]`

Baseada em RÓTULOS:

- Usa nomes das colunas e índices.
- Intervalo inclui o ponto final!

```
df.loc[0:3, ['idade', 'glicose']]
```

`.iloc[linhas, colunas]`

Baseada em POSIÇÃO INTEIRA:

- Usa inteiros de 0 a $N - 1$.
- Semelhante ao slicing de listas.

```
df.iloc[0:4, [1, 2]]
```

Evite Métodos Antigos

O indexador legado `.ix[]` foi completamente removido nas versões modernas do Pandas.

Filtros com Máscaras Lógicas

```
# Operadores bitwise: & (E), | (OU), ~ (NAO)
# Parenteses sao estritamente OBRIGATORIOS ao redor de cada condicao
pacientes_risco = df[(df['idade'] > 60) & (df['glicose'] >= 126)]
```

Inspeção Rápida

- `df.head()`: Primeiras 5 linhas.
- `df.info()`: Tipos de dados e contagem de não-nulos.
- `df.describe()`: Média, desvio padrão, quartis, mínimo e máximo.

Resumo da Aula

- DataFrames são matrizes heterogêneas com índices nomeados para análise rápida.
- Utilize `.loc` para rótulos e `.iloc` para posições numéricas.
- **Prática:** Carregamento de CSVs, seleção colunar e filtros booleanos.