

Ciência dos Dados I: Análise Exploratória

Aula 01: Introdução e História da Computação à Ciência de Dados

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

O Catálogo de Dados: Uma Metáfora Clássica

Na ópera *Don Giovanni* (Mozart / Da Ponte, 1787), o servo Leporello apresenta à nobre Donna Elvira o registro detalhado das conquistas de seu amo:

*"Madamina, il catalogo è questo
delle belle, che amò il padron mio;
un catalogo egli è, che ho fatt'io.*

Osservate, leggete con me.

*In Italia seicento e quaranta, in Almagna duecento e trentuna,
cento in Francia, in Turchia novantuna,
ma in Ispagna son già mille e tre!"*

O que Leporello estava fazendo?

Coleta, categorização por atributos (país, status social, faixa etária) e **agregação estatística**. Um autêntico precursor da análise exploratória de dados!

O que é Ciência de Dados?

- **Não é apenas programação:** requer compreensão do método científico.
- **Não é apenas estatística teórica:** lida com grandes volumes, dados sujos, heterogêneos e fluxo em tempo real.
- **O Diagrama de Venn de Conway:**
 - Habilidades de Computação / Engenharia
 - Matemática e Estatística
 - Conhecimento de Domínio (Física Médica, Biologia, Saúde)

Citação de John Tukey (1962)

"A análise exploratória de dados é uma atitude, uma flexibilidade e uma disposição para buscar coisas além do que esperávamos encontrar."

Marcos Históricos da Computação e Dados

- **Antiguidade:** Tabletes sumérios, ábaco, astrolábios – necessidade milenar de registrar e computar censos e astronomia.
- **Século XIX:**
 - Charles Babbage (Máquina Analítica) e Ada Lovelace (primeiro algoritmo documentado).
 - Censo Americano de 1890: Herman Hollerith introduz cartões perfurados (origem da IBM).
- **Século XX:**
 - Alan Turing (1936-1950): Fundamentos teóricos da computação e inteligência de máquinas.
 - ENIAC e Los Alamos: A computação científica a serviço da simulação física.
 - Seymour Cray (Supercomputadores) e o Sequenciamento do Genoma Humano (anos 1990/2000).
- **Século XXI até 2026:**
 - Do Dilúvio de Dados (*Big Data*) à era dos Grandes Modelos de Linguagem (LLMs) e IA integrada ao pipeline analítico.

O Ciclo Analítico (Framework OSEMN / CRISP-DM)

- ① **Obtain (Obter)**: Conexão a APIs, web scraping, bancos relacionais, arquivos CSV/Parquet.
- ② **Scrub (Limpar / Tratar)**: Tratamento de valores ausentes, inconsistências, normalização de tipos (80% do tempo real de um cientista de dados!).
- ③ **Explore (Explorar - EDA)**: Estatísticas descritivas, distribuições, detecção de anomalias, correlações e visualizações ricas.
- ④ **Model (Modelar)**: Regressão, classificação, clustering ou aprendizado profundo.
- ⑤ **iNterpret (Interpretar e Comunicar)**: Storytelling, relatórios reprodutíveis, painéis e tomada de decisão embasada em evidências.

O Ecossistema Tecnológico do Curso

- **Linguagem:** Python 3.12+
- **Gerenciador:** uv (rápido, determinístico)
- **Ambiente Interativo:** JupyterLab 4 / Google Colab
- **Controle de Versão:** Git e GitHub

Bibliotecas Centrais

- **Manipulação:** Pandas 2.2+, NumPy 2.x
- **Visualização:** Matplotlib 3.9+, Seaborn
- **Modelagem:** Scikit-Learn 1.5+

Resumo e Próximos Passos

- A Ciência de Dados transforma observações brutas em modelos preditivos e conhecimento científico.
- **Na prática de hoje:**
 - Configurar o ambiente interativo.
 - Verificar versões das ferramentas modernas.
 - Clonar o repositório e executar os primeiros testes analíticos.
- Próxima aula: **A Plataforma Jupyter, IPython e Reprodutibilidade Científica.**