

Ciência dos Dados I: Análise Exploratória

Aula 10: Pandas II: Pipeline de Limpeza, Agregação (GroupBy) e Junções (Merge)

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

Tratamento de Dados Ausentes

O Paradigma Split-Apply-Combine

Junção de Tabelas (Joins)

Estratégias para Missing Data

No mundo real, dados faltantes são a regra, não a exceção:

- **Identificação:** `df.isna().sum()` reporta o total de nulos por coluna.
- **Descarte:** `df.dropna(subset=['coluna'])` remove observações incompletas.
- **Imputação:** `df['coluna'].fillna(valor)` preenche ausências com média, mediana ou constante.

```
# Imputando pela mediana (robusta a outliers)
mediana = df['pressao'].median()
df['pressao'] = df['pressao'].fillna(mediana)
```

Agregações Poderosas com groupby

- ❶ **Split:** Divide os dados em grupos com base em critérios.
- ❷ **Apply:** Aplica uma função de cálculo a cada grupo isoladamente.
- ❸ **Combine:** Reúne os resultados em uma única tabela sumária.

```
# Agregacoes multiplas com .agg()
resumo = df.groupby('setor').agg(
    media_temp=('temperatura', 'mean'),
    desvio_temp=('temperatura', 'std'),
    total_pacientes=('id', 'count')
)
```

Relacionando Bases com `pd.merge`

Semelhante ao comando JOIN do SQL:

- **Inner Join** (padrão): Retorna apenas registros presentes em ambas as tabelas.
- **Left Join**: Mantém todas as linhas da tabela da esquerda e anexa atributos da direita.

```
df_final = pd.merge(df_pacientes, df_medicos, on='id_setor', how='left')
```

- O pré-processamento de dados (ETL) viabiliza modelos e estatísticas confiáveis.
- `groupby` e `merge` são as operações de maior retorno analítico no Pandas.
- **Prática:** Imputação de dados faltantes, agregações segmentadas e junções de tabelas.