

Ciência dos Dados I: Análise Exploratória

Aula 11: Computação Científica de Alta Performance com NumPy

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

Por que NumPy?

Vetorização e Universal Functions

Regras de Broadcasting

Estrutura Interna do ndarray

Listas padrão de Python guardam ponteiros para objetos genéricos espalhados na memória heap.

O Array NumPy (`np.ndarray`)

- Bloco contíguo de bytes em memória RAM (escrito em C/Fortran).
- Tipo homogêneo e fixo (`dtype: float64, int32, etc.`).
- Permite ao processador utilizar instruções SIMD (Single Instruction, Multiple Data) e vetorização no nível do hardware.
- Acelerações típicas de **10x a 100x** em relação a loops `for` nativos de Python!

Vetorização: Eliminando Laços Explícitos

Em vez de iterar elemento por elemento, aplicamos a operação ao vetor inteiro:

```
import numpy as np

arr = np.linspace(0, 10, 1_000_000)

# Vetorizacao com Universal Functions (ufuncs)
seno = np.sin(arr)
potencia = arr ** 2
```

Código Limpo e Rápido

A sintaxe aproxima o código Python diretamente da notação matemática da álgebra linear.

Operando em Arrays com Formatos Distintos

Broadcasting descreve como o NumPy trata arrays com shapes diferentes durante operações aritméticas:

- Se os arrays não possuem o mesmo número de dimensões, adiciona-se 1 à esquerda.
- Arrays com tamanho 1 em uma dimensão são "esticados" para coincidir com a dimensão maior sem alocar memória adicional.

```
matriz = np.ones((3, 3)) # Shape (3, 3)
linha = np.array([1, 2, 3]) # Shape (3,) -> tratado como (1, 3)
resultado = matriz + linha # Shape final (3, 3)
```

Resumo da Aula

- NumPy é o alicerce numérico de todo o ecossistema científico (Pandas, SciPy, Scikit-Learn, PyTorch).
- Vetorização e broadcasting viabilizam simulações em larga escala.
- **Prática:** Criação de arrays, benchmarking com `%timeit` e normalização de dados.