

Ciência dos Dados I: Análise Exploratória

Aula 14: Introdução ao Aprendizado de Máquina com Scikit-Learn

Prof. Dr. Ney Lemke

UNESP – Instituto de Biociências de Botucatu

Versão 2026

Sumário da Aula

Da Análise Exploratória à Modelagem

A API do Scikit-Learn

Regressão Linear e Clusterização K-Means

O Continuum da Ciência de Dados

A Análise Exploratória de Dados (EDA) e o Aprendizado de Máquina (ML) são etapas complementares:

- A EDA descobre relações, trata anomalias e orienta a escolha de atributos (*feature selection*).
- O Aprendizado de Máquina quantifica e generaliza esses padrões para fazer previsões ou segmentações sobre novos dados.

Taxonomia Básica de Aprendizado

- **Supervisionado:** Os dados possuem rótulos históricos (y). Exemplos: Regressão (alvo contínuo) e Classificação (alvo discreto/categórico).
- **Não-Supervisionado:** Não há rótulo prévio. O algoritmo agrupa observações por similaridade inerente (ex: Clusterização com K-Means).

O Padrão fit e predict

O Scikit-Learn padronizou o ecossistema com uma interface universal:

```
from sklearn.linear_model import LinearRegression

# 1. Instanciar o estimador com hiperparametros
modelo = LinearRegression()

# 2. Treinar/ajustar aos dados com .fit(X, y)
# X DEVE ser uma matriz 2D (n_amostras, n_features)
# y DEVE ser um vetor 1D (n_amostras,)
modelo.fit(X, y)

# 3. Gerar predicoes com .predict(novos_X)
predicoes = modelo.predict(novos_dados)
```

Dois Métodos Fundamentais

Regressão Linear

Modela a relação entre variável preditora X e desfecho y :

$$\hat{y} = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

Métricas: Coeficiente de determinação (R^2) e Erro Quadrático Médio (RMSE).

Clusterização K-Means

Particiona n observações em k clusters, minimizando a distância euclidiana de cada ponto ao centroide mais próximo:

$$J = \sum_{j=1}^k \sum_{i \in S_j} \|x_i - \mu_j\|^2$$

Conclusão do Curso

- Ao longo dessas 14 aulas, você construiu uma base sólida: da linha de comando Unix, manipulação com Pandas/NumPy, visualização avançada até a modelagem preditiva com Scikit-Learn.
- O pensamento computacional e analítico permite transformar dados brutos em decisões científicas e clínicas de impacto!